



Universidad
Zaragoza

Clasificación Automática

Naive Bayes Probabilidades

Luis Fernando Castillo
@luisfercastillo

Definición Clasificación Supervisada

- Naïve Bayes es uno de los clasificadores más utilizados por su simplicidad y rapidez
- Se trata de una técnica de clasificación y predicción supervisada que construye modelos que predicen la probabilidad de posibles resultados. Constituye una técnica supervisada porque necesita tener ejemplos clasificados para que funcione

ESTÁ BASADA EN EL TEOREMA DE BAYES..

- Está basada en el Teorema de Bayes, también conocido como teorema de la probabilidad condicionada

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$


■ Ejemplo Bayes

- **(Aplicando Teorema de Bayes):** La distribuidora de productos L & M tiene tres proveedores. De cada proveedor si tiene un porcentaje de compra de los productos. Proveedor A tiene el 35% de los productos, proveedor B el 20%, y proveedor C el 45 % de los productos. Por cada uno de ellos se ha definido como política para el flujo de la empresa que se debe restringir el porcentaje de crédito para no tener un valor alto en intereses. Proveedor A de 20%, Proveedor B de 20%, proveedor C de 25%.

Determine:

- a) La probabilidad de que un producto cualquiera se adquiera de contado.
- b) La probabilidad de que un producto cualquiera se haya adquirido por un crédito del proveedor B.

■ Ejemplo Bayes Solución a)




La probabilidad de que un producto cualquiera se adquiera de contado. Es igual a la suma de las probabilidades donde el producto de los proveedores se adquiera de contado.

$$\begin{aligned}
 &+ P(PA) \cdot P(NCA) = 0,255 \\
 &P(PB) \cdot P(NCB) = 0,16 \\
 &P(PC) \cdot P(NCC) = 0,3375
 \end{aligned}$$

0.7525

■ Ejemplo Bayes Solución b)



La probabilidad de que un producto cualquiera se haya adquirido por un crédito del proveedor B.

Calculamos la probabilidad de adquirir un producto a créditos desde cualquier proveedor

Ejemplo 2 - Máquinas

Tenemos dos máquinas (m1 y m2) que fabrican la misma herramienta



Dos máquinas que fabrican la misma herramienta

Ejemplo 2 - Máquinas

Si consideramos que la máquina 1 produce 30 llaves por hora y la máquina 2 produce 20 llaves por hora, de todas las partes producidas se observa que el 1% están defectuosas y de todas las llaves defectuosas el 50% provienen de la máquina 1 y el 50% de la máquina 2.

¿Cuál es la probabilidad de que una pieza defectuosa haya sido producida por la máquina 2?

Ejemplo 2 - Máquinas

Si M1: 30 llaves/hora, M2: 20 llaves/hora
de las defectuosas 50% son de M1 y 50% de M2

$$P(M1) = 30/50 = 0.6$$

$$P(M2) = 20/50 = 0.4$$

$$P(\text{Defecto}) = 1\%$$

$$P(M1 | \text{Defecto}) = 50\%$$

$$P(M2 | \text{Defecto}) = 50\%$$

Lo que deseamos conocer es entonces:

$$P(\text{Defecto} | M2) = ?$$

Aplicando el Teorema de Bayes

$$P(\text{Defecto} | M2) = \frac{P(M2 | \text{Defecto}) P(\text{Defecto})}{P(M2)}$$

Ejemplo 2 - Máquinas

Aplicando el Teorema de Bayes

$$P(\text{Defecto} | M2) = \frac{P(M2 | \text{Defecto}) P(\text{Defecto})}{P(M2)}$$

Teorema de bayes para las máquinas que producen llaves

$$P(\text{Defecto} | M2) = \frac{0.5 * 0.01}{0.4} = 0.0125$$

Sustituyendo el valor de las probabilidades

La probabilidad de que una pieza defectuosa sea de la máquina 2 es del 1.25%

En una producción de 1,000 piezas, entonces 400 provienen de la máquina 2 y si el 1% esta defectuosa habrá 10 piezas defectuosas. de esas 10 piezas el 50% son la máquina 2, es decir 5 piezas, podemos comprobar que el porcentaje de piezas defectuosas de la máquina 2 es $5/400 = 0.0125$

Algoritmo Clasificador

- Supongamos un típico problema de clasificación en Minería de Datos, donde tenemos unos cuantos ejemplos que queremos clasificar. Cada ejemplo (también llamados instancias), se caracteriza por una serie de atributos. Además como estamos en clasificación supervisada, dichos ejemplos deben estar etiquetados, es decir, se debe definir de qué clase son. Por tanto, tenemos un conjunto de 4 ejemplos con 3 atributos cada uno y 2 posibles clases

Algoritmo Clasificador

Ejemplos	Atr. 1	Atr. 2	Atr. 3	Clase
x1	1	2	1	positiva
x2	2	2	2	positiva
x3	1	1	2	negativa
x4	2	1	2	negativa

Caben destacar dos partes en el algoritmo.

- La primera es la construcción del modelo.
- La segunda clasificar un nuevo ejemplo con dicho modelo:

Algoritmo Clasificador

PARTE 1: Crear el modelo.

Para ello se necesitan cuatro pasos:

1. Calcular las probabilidades a priori de cada clase.
2. Para cada clase, realizar un recuento de los valores de atributos que toma cada ejemplo. Se debe distribuir cada clase por separado para mayor comodidad y eficiencia del algoritmo.
3. Aplicar la Corrección de Laplace, para que los valores "cero" no den problemas.
4. Normalizar para obtener un rango de valores $[0,1]$.

Algoritmo Clasificador

PARTE 1: Crear el modelo.

1.1 Calcular las probabilidades a priori

Paso 1: Hay varias formas de establecer la probabilidad a priori a cada clase. La más intuitiva es que todas ellas tengan la misma probabilidad, es decir, 1 dividido entre el número de clases.

Si contamos con la opinión de un experto, puede que éste nos proporciones dichas probabilidades.

En este caso, vamos a considerar cada clase equiprobable. Por tanto:

$$P(\text{positivo}) = 1/2 = 0,5$$

$$P(\text{negativo}) = 1/2 = 0,5$$

Ejemplos	Atr. 1	Atr. 2	Atr. 3	Clase
x1	1	2	1	positiva
x2	2	2	2	positiva
x3	1	1	2	negativa
x4	2	1	2	negativa

Algoritmo Clasificador

PARTE 1: Crear el modelo.

2.1 Recuento de valores de atributos

Paso 2: Para cada clase, realizar un recuento de los valores de atributos que toma cada ejemplo

Ejemplos	Atr. 1	Atr. 2	Atr. 3	Clase
x1	1	2	1	positiva
x2	2	2	2	positiva
x3	1	1	2	negativa
x4	2	1	2	negativa

positivo	valor 1	valor 2
atr.1	1	1
atr.2	0	2
atr.3	1	1

negativo	valor 1	valor 2
atr.1	1	1
atr.2	2	0
atr.3	0	2

PARTE 1: Crear el modelo.

3.1 Suma una unidad a cada valor

Paso 3: Se suma una unidad a cada valor de la tabla anterior

positivo	valor 1	valor 2
atr.1	1	1
atr.2	0	2
atr.3	1	1



positivo	valor 1	valor 2
atr.1	2	2
atr.2	1	3
atr.3	2	2

negativo	valor 1	valor 2
atr.1	1	1
atr.2	2	0
atr.3	0	2



negativo	valor 1	valor 2
atr.1	2	2
atr.2	3	1
atr.3	1	3

PARTE 1: Crear el modelo.

4.1 Recuento de valores de atributos

Paso 4: Se normalizan todos los valores de la tabla del siguiente modo.

Cada celda se divide por la suma de los valores de la fila. Por ejemplo, el valor: "valor 1" del atributo: "atr. 2" se actualiza con: $1 / (1+3) = 0,25$.

positivo	valor 1	valor 2
atr.1	1	1
atr.2	0	2
atr.3	1	1

negativo	valor 1	valor 2
atr.1	2	2
atr.2	3	1
atr.3	1	3

positivo	valor 1	valor 2
atr.1	0,5	0,5
atr.2	0,25	0,75
atr.3	0,5	0,5

negativo	valor 1	valor 2
atr.1	0,5	0,5
atr.2	0,75	0,25
atr.3	0,25	0,75

PARTE 2: Clasificar un nuevo ejemplo . Por ejemplo

$$X5 = \{1,1,1\}$$

Para ello se necesitan dos pasos:

1. Para cada clase disponible, se determinan los valores de probabilidad de cada valor de los atributos del nuevo ejemplo.
2. Aplicar la fórmula de Naïve Bayes

PARTE 2.1: Elección de los valores

$$X5 = \{1,1,1\}$$

Parte 2.1

A continuación se detalla cada paso:

Paso 1: En este caso, se para cada tabla escogemos los valores:

1 de cada atributo, es decir, la primera columna de cada tabla, ya que todos los valores del ejemplo x5 son: 1.

positivo	valor 1	valor 2
atr.1	0,5	0,5
atr.2	0,25	0,75
atr.3	0,5	0,5

negativo	valor 1	valor 2
atr.1	0,5	0,5
atr.2	0,75	0,25
atr.3	0,25	0,75

PARTE 2.2: Aplicar la Fórmula de Naive Bayes

$$\text{Solucion} = \arg \max_{i=1}^n P(c_i) \cdot \prod_{j=1}^m P(a_j | c_i)$$

positivo	valor 1	valor 2
atr.1	0,5	0,5
atr.2	0,25	0,75
atr.3	0,5	0,5

negativo	valor 1	valor 2
atr.1	0,5	0,5
atr.2	0,75	0,25
atr.3	0,25	0,75

Por tanto:

$$P(\text{positivo} | x_5) = 0,5 \cdot (0,5 \cdot 0,25 \cdot 0,5) = 0,03125$$

$$P(\text{negativo} | x_5) = 0,5 \cdot (0,5 \cdot 0,75 \cdot 0,25) = \mathbf{0,046875}$$

Como la clase más probable es "negativa", clasificamos el nuevo ejemplo (x5) como negativo.

Ejercicio

1. Aplique el Clasificador Naive Bayes para el siguiente Conjunto de Datos.

Ejemplo	Antenas	Colas	Núcleos	Cuerpo	Clase
1	1	0	2	Rayado	Normal
2	1	0	1	Blanco	Cancerígena
3	1	2	0	Rayado	Normal
4	0	2	1	Rayado	Normal
5	1	1	1	Rayado	Cancerígena
6	2	2	1	Rayado	Cancerígena

2. Prueba el Clasificador para la Entrada
Antenas=1, Colas = 2, Núcleos=1, Cuerpo=Rayado
3. Sugerencia verificar con **Wekai**. **Siguiente sesión.**
verificar el resultado.

Referencias

- [1] Video demostración del Teorema de Bayes:

Enlace:

<http://www.youtube.com/watch?v=ilvMzBGulHQ>

- [2] Wikipedia: Enlace:
https://en.wikipedia.org/wiki/Naive_Bayes_classifier
- [3] <http://naivebayes.blogspot.com/> mayo 2013
(Cristian Ch)



Clasificación Naive Bayes

Sistemas Inteligentes 2