



EXPLICACIÓN DETALLADA DE Q- LEARNING

Subtítulo de la presentación



INTRODUCCIÓN A Q-LEARNING

Q-Learning es un algoritmo de aprendizaje por refuerzo que busca encontrar la mejor acción a tomar en un estado dado para maximizar la recompensa total.



CONCEPTOS BÁSICOS




Se basa en la idea de aprender una función de valor Q que estima la utilidad de tomar una acción en un estado específico.



ELEMENTOS DEL APRENDIZAJE POR REFUERZO

The general framework of reinforcement learning



Incluye agentes, entornos, estados, acciones y recompensas. El agente interactúa con el entorno para aprender.



FUNCIÓN DE VALOR Q

Three steps from a Q function to the Bellman equation

Step 1:

Recursive expansion of Q

$$Q(s_t, a_t) = r_t + \gamma Q(s_{t+1}, a_{t+1})$$

Step 2:

Truncate last Q value

$$Q(s_t, a_t) = r_t + \gamma(1 - d)Q(s_{t+1}, a_{t+1})$$

Step 3:

Optimal Q value

$$Q^*(s_t, a_t) = r_t + \gamma(1 - d) \max_a Q(s_{t+1}, a_{t+1})$$

La función $Q(s, a)$ representa el valor esperado de tomar la acción a en el estado s , siguiendo una política determinada.



ECUACIÓN DE BELLMAN

La ecuación de Bellman es fundamental para actualizar los valores Q , permitiendo al agente aprender de las recompensas futuras.

Bellman Equation

$$Q(s, a) = R(s) + \gamma \max_{a'} Q(s', a')$$

$$Q(s, a) = R(s)$$

$$\begin{aligned} s &= 2 \\ a &= \rightarrow \\ s' &= 3 \end{aligned}$$

100 100	50	12.5	25	6.25	12.5	10	6.25	20	40	40
100	0		0		0		0			40
1	2	3	4	5	6					

$$\begin{aligned} Q(2, \rightarrow) &= R(2) + 0.5 \max_{a'} Q(3, a') \\ &= 0 + (0.5)25 = 12.5 \end{aligned}$$

$$\begin{aligned} Q(4, \leftarrow) &= R(4) + 0.5 \max_{a'} Q(3, a') \\ &= 0 + (0.5)25 = 12.5 \end{aligned}$$


$$\begin{aligned} s &= 4 \\ a &= \leftarrow \\ s' &= 3 \end{aligned}$$



PROCESO DE ACTUALIZACIÓN DE Q


$Q(s, a) = Q(s, a) + \alpha [r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$, donde α es la tasa de aprendizaje y γ es el factor de descuento.

The higher the iterations number, better is the Q-table results



EXPLORACIÓN VS EXPLOTACIÓN

El dilema entre explorar nuevas acciones para descubrir recompensas potenciales y explotar acciones conocidas para maximizar recompensas.



POLÍTICA E-GREEDY

Una estrategia común para balancear exploración y explotación, donde ϵ es la probabilidad de explorar acciones aleatorias.

Pseudo Code

```
p = random()

if p <  $\epsilon$ :
    pull random action
else:
    pull current-best action
```



CONVERGENCIA DE Q-LEARNING

Bajo ciertas condiciones, Q-Learning converge a la función de valor óptima, garantizando la mejor política posible.



VENTAJAS DE Q-LEARNING

Es simple de implementar, no requiere un modelo del entorno y puede manejar problemas con espacios de estado grandes.

Advantages over Q-learning

- Each step of experience potentially used in many weight updates.
- Learning directly from consecutive samples is inefficient, due to strong correlations between samples. Randomizing the samples breaks these correlations.
- Note “off-policy” learning (current parameters different from those used to generate the sample)
- Uniform sampling of experience gives equal importance to all transitions – this could be a bad thing...



LIMITACIONES DE Q-LEARNING


	On-Policy	Off-Policy
Advantages	• Learns safer strategy • Often converges faster • Often has better online performance	• More likely to find optimal policy • Less likely to get stuck in local minimum • Can utilize experience replay • Data can be collected via various method
Disadvantages	• May become trapped in local minima • Less likely to find optimal policy • Data must be collected following current policy	• Policy learned may not be as safe • May not perform as well online

Puede ser ineficiente en problemas con espacios de estado continuos y sufre de problemas de convergencia lenta.




MEJORAS AL Q-LEARNING

Incluye técnicas como Q-Learning profundo, que utiliza redes neuronales para aproximar la función de valor Q.



APLICACIONES DE Q-LEARNING




Se utiliza en robótica, juegos, sistemas de recomendación y más, donde el aprendizaje autónomo es crucial.



EJEMPLO PRÁCTICO

Demostración de un problema de laberinto donde un agente aprende a encontrar la salida utilizando Q-Learning.



CONCLUSIONES

Q-Learning es una herramienta poderosa en el aprendizaje por refuerzo, con aplicaciones prácticas y teóricas significativas.

