

Montecarlo

Montecarlo

Programación dinámica



$\{S, A, R, p, \gamma\}$

Monte Carlo

$\{S, A, R, p, \gamma\}$

No existe modelo del entorno

Montecarlo

$$v_{\pi}(s) = \mathbb{E}_{\pi} \left[\sum_{k=0}^{\infty} \lambda^k R_{t+k+1} | S_t = s \right]$$



Estimación función
estado valor



Promedio



Múltiples trayectorias (Iteraciones)

$$\tilde{v}_{\pi}(s) = \mathbb{E}_{\pi} \left[\sum_{k=0}^{\infty} \lambda^k R_{t+k+1} | S_t = s \right]$$

$$\tilde{q}_{\pi}(s, a) = \mathbb{E}_{\pi} \left[\sum_{k=0}^{\infty} \lambda^k R_{t+k+1} | S_t = s, A_t = a \right]$$

Si se analiza el
valor es
predicción

$$\pi^*(a|s)$$

PREDICCIÓN CON
MONTE CARLO
(EVALUACIÓN)

CONTROL CON
MONTE CARLO
(POLÍTICA ÓPTIMA)

Si se analiza
la función
acción valor
será control

Montecarlo

- Los métodos de Monte Carlo en aprendizaje por refuerzo son algoritmos que **estiman las funciones de valor** al recopilar episodios completos de interacción con el entorno y calcular recompensas acumuladas basadas en las trayectorias observadas

Montecarlo

En el contexto de un **mundo grilla** (gridworld), estos métodos permiten evaluar estados y políticas mediante:

- 1.Promedio de retornos:** Calculan el valor de cada estado como el promedio de las recompensas acumuladas a largo plazo obtenidas al visitarlo.
- 2.Muestreo directo:** No requieren un modelo del entorno, sino únicamente muestras de episodios completos. (Como las probabilidades de transición entre estados ni las recompensas asociadas a dichas transiciones)
- 3.Evaluación de políticas:** Comparan políticas mejorando iterativamente la acción elegida en cada estado según los retornos observados.

Montecarlo

- Los métodos de Monte Carlo en RL se dividen en dos partes, al igual que la iteración de políticas: **Predicción de MC** y **Control de MC**.

Predicción Montecarlo

Predicción MC

- De manera muy similar a cómo evaluamos la función de valor para la evaluación de políticas, nos centraremos en evaluar la **función q** en la predicción de MC.
- Nuevamente, la pregunta será: "dada una política, ¿cuál es la función q para esa política correspondiente?"

$$q_{\pi}(s, a) = \mathbb{E} \left[\sum_{k=0}^T \gamma^k R_{t+k+1} \mid S_t = s, A_t = a \right]$$

Predicción MC

$$q_{\pi}(s, a) = \mathbb{E} \left[\sum_{k=0}^T \gamma^k R_{t+k+1} \mid S_t = s, A_t = a \right]$$

- La función q es básicamente la **suma de las recompensas esperadas** en un episodio hasta el paso de tiempo terminal dado el par estado-acción actual (s, a) siguiendo la política π .

Predicción MC

- Sin embargo, como no conocemos la función de transición de estado para el entorno en MC, NO nos es posible calcular la expectativa ya que **NO conocemos las probabilidades** asociadas con cada recompensa.


$$q_{\pi}(s, a) = \mathbb{E} \left[\sum_{k=0}^T \gamma^k R_{t+k+1} \mid S_t = s, A_t = a \right]$$

Predicción MC

- Sin embargo, lo que podemos hacer es **ejecutar una serie de episodios con acciones aleatorias** y observar las recompensas recibidas en cada episodio.

Predicción MC

$Q(S_0, \text{Right})$




0	1	5
0	-1	0
-2	5	10

Terminal

- Los valores representan las recompensas por la transición a ese estado.
- El estado con +10 recompensas es el estado terminal

Predicción MC

$Q(S_0, \text{Right})$




0	1	5
0	-1	0
-2	5	10

Terminal

- Dado este pequeño mundo cuadrícula, nuestro objetivo es calcular el valor q de estar en el estado S_0 y tomar la acción correcta.
- Recordemos que en los métodos de MC tenemos que promediar las recompensas.
- Esto significa que tenemos que calcular la media empírica en lugar de la expectativa, ya que no conocemos las probabilidades.

Ejemplo

Ejemplo



$$G = \left[\sum_{k=0}^{\infty} \lambda^k R_{t+k+1} | S_t = s \right], \gamma = 0.9$$

Episodio	Trayectoria	Retorno (G)
1	0 → 1 → 2 → 6 → 7	0
2	0 → 1 → 2 → 6 → 5	0
3	0 → 1 → 2 → 6 → 10 → 9 → 13 → 14 → 15	0.43
4	0 → 4 → 5	0
5	0 → 4 → 8 → 9 → 10 → 14 → 15	0.53
6	0 → 4 → 8 → 12	0
7	0 → 1 → 2 → 3 → 2 → 6 → 10 → 9 → 8 → 9 → 13 → 14 → 15	0.28
8	0 → 1 → 2 → 6 → 10 → 6 → 7	0
9	0 → 1 → 0 → 4 → 8 → 9 → 5	0
10	0 → 1 → 2 → 3 → 2 → 1 → 5	0


Ejemplo



Episodio	Trayectoria	Retorno (G)
1	0 → 1 → 2 → 6 → 7	0
2	0 → 1 → 2 → 6 → 5	0
3	0 → 1 → 2 → 6 → 10 → 9 → 13 → 14 → 15	0.43
4	0 → 4 → 5	0
5	0 → 4 → 8 → 9 → 10 → 14 → 15	0.53
6	0 → 4 → 8 → 12	0
7	0 → 1 → 2 → 3 → 2 → 6 → 10 → 9 → 8 → 9 → 13 → 14 → 15	0.28
8	0 → 1 → 2 → 6 → 10 → 6 → 7	0
9	0 → 1 → 0 → 4 → 8 → 9 → 5	0
10	0 → 1 → 2 → 3 → 2 → 1 → 5	0


$$\widetilde{v}_{\pi}(s=0) = \frac{0 + 0 + 0 + 0.43 + 0 + 0.53 + 0 + 0.28 + 0 + 0 + 0}{10} = 0.124$$

Eso quiere decir que el valor del estado cero será de 0.124. Entre mas iteraciones mejor la aproximación. Esto se debe realizar por cada estado



Se puede calcular el retorno por Múltiples visitas

0 → 1 → 0 → 4 → 8 → 9 → 5



Como también solo calcular el retorno por una única visita
(Primera visita)

0 → 1 → 0 → 4 → 8 → 9 → 5

Entrada:

- $\pi \leftarrow$ la política a evaluar

Inicializar:

- $V(s) \leftarrow$ valores arbitrarios para cada estado “s” (que se actualizará con el algoritmo)
- $\text{Retornos}(s) \leftarrow$ lista vacía (que contendrá el valor del retorno obtenido para cada estado “s”)

Repetir K veces y en cada iteración:

(a) Generar un episodio usando π

(b) $G \leftarrow 0$ (inicializar el retorno a calcular)

(c) Por cada instante de tiempo “t” en el episodio:





- $G \leftarrow \gamma G + R_{t+1}$ (actualizar el retorno)
- Si es la primera visita a “s”:
 - $\text{Retornos}(s) \leftarrow [\text{Retornos}(s), G]$ (agregar el retorno calculado)
 - $V(s_t) \leftarrow \text{promedio}(\text{Retornos}(s))$ (y promediar los retornos para obtener la función estado-valor)

Ejemplo

Ejemplo


- Primero, inicializaremos todos nuestros valores q en 0 y estableceremos una política estocástica aleatoria π . Reproduciremos 4 episodios y acumularemos 4 retornos. Ahora será fácil calcular la media incremental. El factor de descuento se toma como 1 para simplificar la explicación.

$Q(S_0, \text{Right})$




Ejemplo

$Q(s_0, \text{Right})$




Ejemplo de retorno 1:

$$G_t = 0 + 1 + 5 + 0 + 10 = 16$$




Ejemplo de retorno 3:

$$G_t = 0 + 1 + 5 + 0 - 1 + 0 - 2 + 5 + 10 = 18$$



Ejemplo de retorno 2:

$$G_t = 0 + 1 - 1 + 0 + 10 = 10$$



Ejemplo de retorno 4:

$$G_t = 0 + 1 + 5 + 0 - 1 + 5 + 10 = 20$$

$$q_\pi(s_0, \text{right}) = \frac{16 + 10 + 18 + 20}{4} = 16$$

Ejemplo

- Al utilizar la media incremental, podemos estimar el valor q de estar en el estado S_0 y tomar la acción correcta. Pero surge una pregunta: ¿cómo nos garantizará el cálculo de la media empírica que este valor q será la aproximación precisa de la función q para la política dada?

$$q_{\pi}(s_0, \text{right}) = \frac{16 + 10 + 18 + 20}{4} = 16$$

Ejemplo

- Según la ley de los grandes números, a medida que aumenta el tamaño de una muestra, su media se acerca al promedio de toda la población.
- En la predicción de MC, a medida que el número de muestras devueltas se acerca al infinito, el promedio de todas esas muestras devueltas será cada vez más una estimación precisa del valor q .



Montecarlo

- **¡Ésta es la esencia de los Métodos de Monte Carlo!**
- Pudimos evaluar la función $q_function$ SIN tener que conocer la dinámica del entorno.

Montecarlo

- Otra forma de encontrar el valor medio de los rendimientos totales es actualizar el incremento medio utilizando la siguiente regla de actualización:

$$Q \leftarrow Q + \frac{1}{N}(G - Q)$$

- Q representa el valor q para un par estado-acción
- G es el rendimiento actual acumulado después de que el episodio ha terminado
- N es el número total de veces que se ha encontrado ese par estado-acción
- G - Q se denomina **diferencia temporal** , ya que estamos restando el antiguo rendimiento promedio (Q) del nuevo rendimiento (G).

- Es importante recordar que **los valores Q se actualizan después de que finaliza un episodio en Monte Carlo Learning**

Montecarlo

- Otra cosa interesante que cabe destacar es que una vez que el valor de N se vuelve relativamente grande, la diferencia temporal no tendrá mucho efecto en la actualización del valor Q .
- Esto es un problema porque las actualizaciones en los episodios anteriores se verán favorecidas más que las actualizaciones en los episodios posteriores, lo que hace que nuestro algoritmo esté sesgado.
- Para combatir esta noción, multiplicaremos por un alfa constante en lugar de N

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha(G_t - Q(S_t, A_t))$$

Montecarlo

- Ahora que podemos calcular el valor q para cada par estado-acción, todo lo que tenemos que hacer es ejecutar muchos episodios hasta que la función q aleatoria se convierta en la verdadera función q para la política π

$$q_k \approx q_\pi \quad \text{as } k \rightarrow \infty$$